Capitolo 1

Introduzione e Definizione del Problema

L'**anomaly detection** (o outlier detection), è il processo che mira ad identificare i dati che deviano in modo significativo dalla maggioranza delle osservazioni, portando a presupporre che siano generati da un meccanismo differente.

Individuare queste irregolarità comporta sfide uniche dovute alla natura intrinseca del problema. Tra le principali complessità sono presenti:

- l'incognita delle anomalie: le anomalie rimangono sconosciute finché non si verificano.
- l'eterogeneità delle anomalie: le diverse classi di anomalie possono avere caratteristiche totalmente diverse tra loro.
- la rarità delle anomalie: vi è un grande squilibrio di classe rispetto la maggioranza di dati normali. [19]

Il processo di rilevamento delle anomalie ha una lunga storia, costituita da studi e applicazioni di metodologie sempre più innovative che puntano alla risoluzione delle molteplici sfide che caratterizzano la materia. Le principali per le quali le tecnologie moderne, in particolare il deep learning, giocano un ruolo fondamentale sono:

1. **Basso tasso di richiamo (Recall)**: data la rarità e l'eterogeneità delle anomalie, alcuni metodi possono generare dei "falsi positivi". La sfida è quella, quindi, di ridurre i falsi positivi, aumentando le capacità di individuare le vere anomalie.
2. **Dati ad alta dimensionalità e interdipendenti**: le anomalie, evidenti in poche dimensioni, tendono a scomparire all'aumentare della complessità dei dati. Inoltre, risulta sfidante individuare anomalie quando le istanze sono interdipendenti tra loro.

3. **Apprendimento efficiente con pochi dati**: ottenere grandi quantità di dati anomali spesso è costoso e poco pratico. La sfida è riuscire a massimizzare lo sfruttamento dei dati parzialmente etichettati per poter distinguere i dati normali dalle anomalie e quindi generalizzare il modello anche per anomalie mai viste prima.

4. **Resilienza al rumore**: i dati di addestramento reali non sono quasi mai perfettamente puliti, ma anzi spesso contengono etichette errate o anomalie non classificate. Sorge necessario sviluppare modelli capaci di tollerare, o ancor meglio sfruttare questi dati.

5. **Rilevamento di anomalie complesse**: la maggior parte dei sistemi classici è addestrata in modo tale da concentrarsi su singole anomalie puntuali, è necessario espandere il rilevamento ad anomalie contestuali o collettive. La sfida è quella di creare, quindi, modelli capaci di ricordare il contesto e valutare interi gruppi di dati.

6. **Spiegabilità (Anomaly Explanation)**: spesso i modelli complessi agiscono come scatole nere. Oltre a rilevare un'anomalia, il sistema deve fornire delle motivazioni che siano interpretabili. Questa "trasparenza" è fondamentale per garantire affidabilità (soprattutto in domini critici), permettere la supervisione umana e garantire l'ottimizzazione del modello bilanciando potenza e verificabilità.

L'applicazione di metodi basati sul deep learning riesce quindi a superare i limiti dei metodi più tradizionali, ottimizzando il processo interamente e apprendendo rappresentazioni specifiche per il rilevamento di anomalie. Riescono a sfruttare dati parzialmente etichettati, complessi e anche ad alta dimensionalità, unificando il rilevamento e la spiegazione in un unico sistema.

1.1 L'anomaly detection nella Computer Vision

La Visual Anomaly Detection (VAD) è un punto cruciale nel campo del machine learning e della computer vision in quanto l'obiettivo è identificare, all'interno di dati visivi come ad esempio immagini o nuvole di punti, ciò che devia rispetto ad un concept stabilito di "normalità". [6] Rispetto alla maggior parte dei metodi di machine learning classici, che assumono di operare in un sistema statico e chiuso, in cui tutte le classi sono note a priori; la VAD studia come i modelli possano gestire informazioni sconosciute e incerte in un ambiente aperto e dinamico. [26]

A seconda del grado di ispezione, la VAD si divide in **image-level**, stabilendo se l'intera immagine è anomala e **pixel-level**, in cui viene localizzata l'esatta regione del difetto, rivelandosi vitale in campi come l'ispezione di difetti industriali, identificazione di lesioni mediche e rilevamento di ostacoli nella guida autonoma. [26][19].

1.1.1 Sfide Principali dell'Anomaly Detection

Negli ultimi anni, l'integrazione di sistemi intelligenti e dell'Internet of Things (IoT) all'interno dei processi industriali ha contribuito a generare una mole di dati senza precedenti. In questo contesto, garantire l'integrità, la sicurezza e l'affidabilità dei dati è un requisito fondamentale per garantire continuità operativa. Il rilevamento delle anomalie, diventa centrale per far fronte a questa necessità, configurandosi come strumento cardine per identificare tempestivamente guasti meccanici, difetti di produzione, o minacce informatiche prima che diventino fermi macchina o rischi per la sicurezza. Nonostante i grandi successi del Deep Learning e del Machine Learning in scenari controllati, trasferire queste tecnologie in realtà operative presenta ostacoli non banali.[20][27][21]

Per riuscire a progettare soluzioni robuste e dispiegabili sul campo, risulta indispensabile analizzare tre sfide principali:

1. Sbilanciamento delle classi.

   I dataset, in particolare quelli industriali, presentano una rarità di dati anomali rispetto a quelli che definiscono il normale funzionamento. In linee di produzione efficienti, infatti, i dati relativi ai guasti sono estremamente sporadici. Questa asimmetria estrema rende approcci classici spesso inefficaci. Essi, infatti, tendono a soffrire di un bias sistematico verso la classe maggioritaria (quella normale), non riuscendo a generalizzare e riconoscere i rari eventi critici.[27] [20]

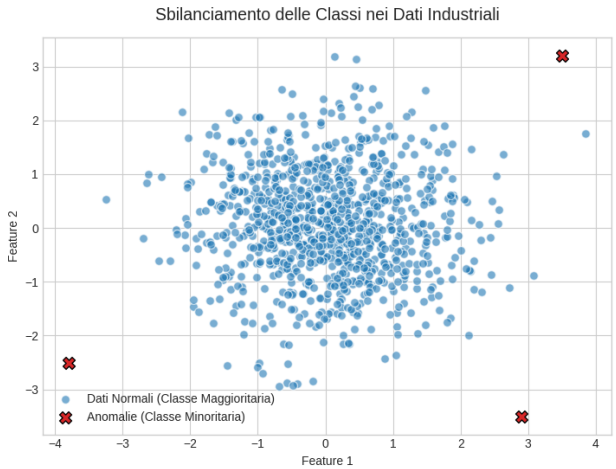


Figura 1.1: Rappresentazione dello sbilanciamento estremo tra dati di normale funzionamento e rari eventi anomali.

2. Variabilità ed eterogeneità dell'anomalia.

Le anomalie presentano caratteristiche di estrema eterogeneità e una natura senza confini definiti. Un malfunzionamento non si manifeste quasi mai secondo un pattern identico, ma anzi può configurarsi come un picco improvviso, un comportamento collettivo anomalo o un'anomalia contestuale. Poiché i guasti sono infinitamente diversificati, risulta impossibile poter mappare tutte le possibili configurazioni di anomalia all'interno di un singolo modello. Per questo, l'algoritmo deve possedere una spiccata capacità di astrazione, riuscendo a catalogare come anomalia qualsiasi entità fuori dallo spazio "normale" anche se mai vista in addestramento.[27] [20][21]

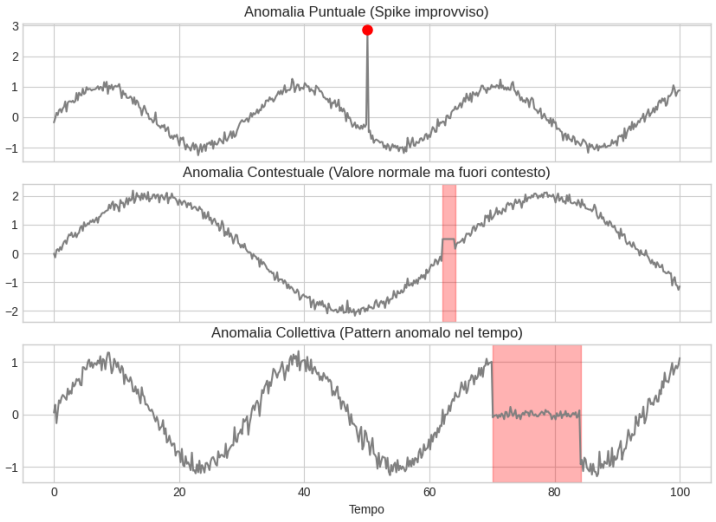


Figura 1.2: Rappresentazione delle tre diverse tipologie di anomalia in una serie temporale: puntuale, contestuale e collettiva.

3. Vincoli e complessità dei contesti industriali.

   I dati sensoriali di una fabbrica sono strettamente legati ad una forte dipendenza del contesto. Un determinato valore di vibrazione o di temperatura può essere considerato perfettamente normale in un determinato momento, come ad esempio, in una particolare stagione, o in una determinata fase produttiva, ma può essere considerata un'anomalia in altri momenti. I confini tra anomalia e normalità, sono sfumati e ambigui. I campioni presentano spesso fluttuazioni insolite, dovute a tolleranze industriali che potrebbero ricalcare i tratti delle anomalie, generando falsi positivi. Il modello deve, quindi, essere progettato con l'integrazione di feature contestuali per evitare che il modello risulti rigido e non adattabile ai cambi di scenario. Diventa fondamentale riuscire ad implementare una fase di pre-elaborazione per mitigare l'effetto dei disturbi sensoristici.[27] [20][21]

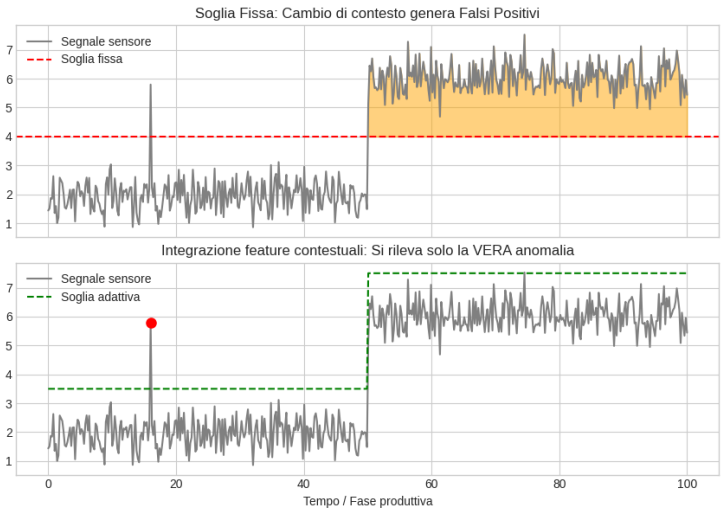


Figura 1.3: Confronto tra l'uso di una soglia di anomalia fissa (che genera falsi positivi al cambio di fase produttiva) e una soglia adattiva basata sul contesto.

1.1.2 Definizioni dei Paradigmi

Le sfide appena descritte — in particolare la rarità dei difetti e l'imprevedibilità del contesto industriale — rendono impossibile l'adozione di un'unica architettura universale. A seconda della disponibilità, della qualità e della mole di dati raccolti, la progettazione del modello deve adattarsi seguendo approcci di addestramento differenti. Vengono, quindi, definiti tre principali paradigmi che hanno guidato lo sviluppo delle metodologie di Visual Anomaly Detection. [26]

- **Paradigma Supervisionato (Supervised Visual Anomaly Detection)**

  Il modello supervisionato (o apprendimento supervisionato) si basa su un paradigma fondamentale: l'algoritmo impara a compiere una determinata associazione o previsione partendo da un dataset di addestramento strutturato in **coppie di input e output attesi (etichette o labels)**. Questo paradigma funziona tramite una guida diretta:

  - **Presenza di etichette (Labels):** ogni dato di input è associato ad una risposta corretta definita da un supervisore umano. Il modello viene quindi addestrato esplicitamente a riconoscere il difetto e a classificarlo come tale.
  - **Definizione dei Confini di Classe:** ricevendo input di entrambe le categorie (buone e difettose), il modello supervisionato riesce a definire i confini decisionali (class boundaries) con estrema precisione, riducendo falsi allarmi e identificando esattamente un oggetto conforme da un non conforme.[2]

Le etichette sono soggette a differenti livelli di granularità in base al diverso metodo applicato. Nella supervisione a livello di immagine (Weakly Supervised) viene fornito solo un flag booleano (ad esempio 0 per sano, 1 per difettoso); mentre, nella supervisione a livello di Pixel (Pixel-level Supervised), viene richiesto uno sforzo umano più minuzioso, in quanto è necessario il disegno di maschere millimetriche attorno ad ogni singolo difetto. Quest'ultimo metodo, è molto potente ma estremamente costoso e lento e spesso impraticabile in contesti complessi. Nonostante l'elevata accuratezza del modello a livello teorico, però, i paradigmi supervisionati presentano ostacoli molto impattanti quando applicati a scenari reali. Essi, difatti, necessitano di grandi quantità di dati che siano esemplificativi per ogni classe; tuttavia, nelle linee di produzione reali, i difetti non sono così numerosi. Il modello finisce per andare in **overfitting**: a causa di dataset di training sbilanciati, con una presenza minima di difetti, il modello memorizza perfettamente i difetti visionati, ma perde la capacità di generalizzare. I difetti sconosciuti, in questo modo, verranno classificati come "sani" solamente a causa di una non conformità con i difetti appresi.[2]

- **Paradigma non Supervisionato (Unsupervised Visual Anomaly Detection)**

  L'approccio non supervisionato consente di costruire modelli di rilevamento senza dover fare affidamento ad etichette o campioni annotati. In questo scenario, infatti, non sono presenti dati che addestrino il modello anticipandogli cosa sia "normale" e cosa sia "difettato". [7] Il paradigma non supervisionato si basa su alcune premesse fondamentali:

  – scarsità statistica delle anomalie: si assume, come visto anche in precedenza, che le anomalie sia rare e minoritarie;
  – differenziazione della norma: l'obiettivo non è raggruppare oggetti simili, ma determinare i campioni che sono più distanti o differenti dalla maggioranza dei dati;
  – deviazione dal pattern: l'identificazione dell'anomalia avviene perché non sufficientemente simile al resto dei dati, e la differenza è misurata tramite specifiche caratteristiche, le **feature**.[12]

  L'approccio non supervisionato presenta alcuni vantaggi, tra cui sicuramente l'abbattimento di tempi e costi. Non sorge, difatti, la necessità di etichettare manualmente e capillarmente i campioni. Un ulteriore vantaggio è il rilevamento delle anomalie sconosciute, in quanto esse vengono riconosciute attraverso l'analisi della differenza tra il campione e il modello di "normalità".[7] Il modello si presenta, inoltre, robusto rispetto alla contaminazione dei dati, riuscendo ad isolare e apprendere la normalità anche in presenza di dataset "sporchi".[15]

- **Paradigma Semi-Supervisionato (Semi-Supervised Anomaly Detection** Il modello semi supervisionato utilizza un set di addestramento che contiene esclusivamente istanze etichettate della classe "normale".

Non è necessario quindi possedere delle etichette per la classe delle anomalie. Questo paradigma, risulta anch'esso essenziale data la nota rarità di anomalie e istanze "non normali". Per far fronte a queste necessità, si utilizzano tecniche a singola classe, che definiscono un confine decisionale, un **boundary**, attorno alla classe negativa, permettendo di isolare la regolarità dei dati normali rispetto gli anomali. Questo metodo, consente di rilevare tipologie di anomalie inedite che non erano mai apparse durante l'addestramento. Gli algoritmi che seguono questo paradigma si suddividono in due categorie principali:

- individuali: operano come modelli singoli. Tra le logiche che caratterizzano questi modelli possiamo distinguere i *modelli lineari*, quelli *basati sulla prossimità*, i *modelli probabilistici*, e le *reti neurali*.
- ensemble: riunisce e fonde più logiche sfruttando i risultati di molteplici classificatori individuali. La regola alla base è che una collezione di classificatori quasi identici non potrà mai superare le prestazioni dei suoi singoli componenti. Esempi possono essere *l'isolation forest* e *l'extreme gradient boosting outlier detection*.

Il paradigma presenta sicuramente vantaggi quali la scoperta di anomalie conosciute (Zero-Day) e l'efficacia in casi di sbilanciamento delle classi. Allo stesso tempo però, il modello è sensibile al "rumore" nei dati e potrebbe presentare un degrado delle prestazioni in contesti specifici, come ad esempio l'elaborazione di dati esclusivamente con feature di tipo nominale.[24]

In sintesi, l'analisi dei paradigmi... [Testo Scelto] In sintesi, l'analisi dei paradigmi di apprendimento evidenzia come la scelta dell'approccio dipenda strettamente dalla natura e dalla disponibilità dei dati industriali. Sebbene i metodi supervisionati offrano un'elevata precisione, la rarità intrinseca delle anomalie spinge la ricerca verso soluzioni semi-supervisionate, capaci di modellare la "normalità" in modo flessibile e resiliente. Tuttavia, la sola definizione del paradigma non è sufficiente a garantire il successo in contesti operativi complessi. Risulta quindi fondamentale analizzare come queste logiche siano state declinate concretamente all'interno della letteratura scientifica recente.

1.2 Il Benchmark MVTec AD e le Metriche di valutazione

Al fine di validare l'efficacia degli algoritmi di *Anomaly Detection* nel contesto industriale, è indispensabile avere un quadro sperimentale standardizzato e condiviso dalla comunità scientifica. Per molto tempo, l'assenza di dati reali e uniformi ha limitato le possibilità di un confronto oggettivo fra le diverse architetture. Questa lacuna è stata colmata dall'introduzione del dataset **MVTec**

Anomaly Detection (MVTech AD), che si è affermata come il benchmark di riferimento per il controllo di qualità industriale.

Verrà analizzata la struttura del dataset, evidenziandone le sfide geometriche poste dalle diverse categorie di materiali contenuti, per poi definire le metriche statistiche utilizzate per misurare e confrontare la sensibilità dei modelli.

1.2.1 Analisi del Benchmark: Texture vs Oggetti Strutturati

Il dataset MVTech AD originale è stato introdotto per far fronte alla carenza di dataset reali e comprensivi per il rilevamento non supervisionato delle anomalie. È composto da 5354 immagini a colori e ad alta risoluzione. Le immagini sono così suddivise:

- **5 categorie di Texture:** rappresentano superfici continue e si suddividono in texture regolari e irregolari. Includono legno, pelle, tappeti, grigle e piastrelle.

- **10 categorie di Oggetti:** rappresentano elementi con confini definiti. Includono oggetti rigidi, come ad esempio dadi di metalli, viti, bottiglie, pillole; oggetti deformabili, come cavi ed elementi naturali.

Il database contiene oltre 70 tipi diversi di difetti. Sono presenti sia difetti superficiali, come graffi, ammaccature, sia difetti strutturali gravi, come parti mancanti o piegate. Inoltre, per poter permettere non solo il rilevamento dell'anomalia ma anche la localizzazione esatta della stessa, il DB fornisce 1888 maschere di *ground truth* che consistono in annotazioni estremamente precise per consentire la localizzazione della posizione del difetto per ogni singolo pixel. [4]

Il dataset ha subito negli anni delle evoluzioni per far fronte le limitazioni che sono sorte dall'avanzamento e dall'affinamento delle tecniche di analisi.

In particolare, è stato rilasciata una prima versione evoluta del dataset, in particolare **MVTech LOCO AD (Logical Constraints Anomaly Detection**. Sviluppato per far fronte alle anomalie logiche, con 3644 immagini con prodotti che sono fisicamente intatti, ma presentano delle violazioni delle regole di assemblaggio, come ad esempio un pezzo valido ma inserito nello scomparto errato.[18]

Negli ultimi anni, gli aggiornamenti del database si sono rifocalizzati sulle anomalie strutturali, estremizzandone la complessità visiva e ottica. **MVTec AD 2**, ha introdotto il caos e i limiti fisici del mondo reale, senza cambiare la logica del difetto. Con l'evoluzione delle tecnologie e dei metodi, i benchmark standard avevano raggiunto un limite fisiologico che non permetteva il confronto delle performance in caso di algoritmi strutturalmente e architetturalmente superiori, per questo si è reso necessario avere un nuovo standard per sbloccare il progresso della ricerca.

In questa versione aggiornata sono presenti non solo oltre 8000 immagini ad alta risoluzione, ma introduce anche nuovi scenari di analisi che replicano i casi più ostici dell'industria moderna. Le innovazioni principali sono:

- **Merci sfuse e oggetti sovrapposti:** spesso elementi come riso o tasselli da muro, sono ammucchiati, in posizioni casuali e sovrapposti, e quindi è richiesta una comprensione semantica molto più profonda.
- **Trasparenza e semi-trasparenza:** materiali come fiale di vetro o gelatine generano riflessi, rifrazioni e distorsioni naturali, che rendono complessa la distinzione tra un difetto interno e un gioco di luce.
- **Alta variabilità "normale":** molti materiali presentano micro-difetti tollerati. L'algoritmo deve quindi imparare ad ignorare il "rumore di fondo" e rilevare solo le anomalie strutturali.
- **Difetti microscopici:** sono stati introdotti difetti microscopici rispetto la risoluzione totale dell'immagine, così da poter testare la capacità dei modelli di estrarre feauture a grana finissima senza perdersi nel contesto.

MVTec AD 2, si propone quindi come benchmark adatto a testare la robustezza percettiva dei modelli. [13]

1.2.2 Criteri di Validazione e Metriche di Performance

Nel campo della visione artificiale, il rilevamento non supervisionato delle anomalie e la loro precisa localizzazione rappresentano sfide cruciali e di grande applicazione pratica. [29] Dalla pubblicazione originale del dataset MVTec AD, la rapida e continua evoluzione degli algoritmi ha spinto le prestazioni dei modelli verso una quasi totale saturazione. [29] Di conseguenza, per valutare oggettivamente i reali progressi dei nuovi algoritmi, è stato necessario l'impiego di metriche di valutazione rigorose, capaci di quantificare accuratamente sia l'identificazione globale dell'anomalia sia la sua esatta localizzazione spaziale. [29]

- **Image-level AUROC**

  Questa metrica rappresenta lo standard per valutare le prestazioni di *rilevamento* globale. Essa quantifica la capacità del modello di assegnare all'intera immagine un punteggio complessivo, permettendo di discriminare in modo affidabile un campione sano da uno difettoso. [29] Nel contesto di ispezione industriale, questa misurazione è fondamentale per determinare il livello di affidabilità dei sistemi automatizzati di scarto. Le valutazioni comparative basate sull'Image-level AUROC hanno ampiamente dimostrato che le moderne architetture basate sulla rappresentazione (representation-based) tendono a ottenere risultati nettamente superiori rispetto ai classici approcci basati sulla ricostruzione dell'immagine (reconstruction-based). [29]

- **Pixel-level AUROC**

  I sistemi di visione artificiale, oltre a identificare un pezzo difettoso, devono essere in grado di localizzare l'esatta posizione dell'anomalia. L'AUROC a livello di pixel valuta tale accuratezza spaziale trattando ogni singolo pixel dell'immagine in modo indipendente. [29] La metrica calcola l'area sotto la curva ROC basandosi sulla correttezza della previsione (sano/anomalo) fornita dal modello per ciascun pixel. [29]

  Tuttavia, studi recenti hanno fatto emergere una forte criticità statistica legata a questa misurazione: raggruppando tutti i pixel dell'immagine in modo indiscriminato, la metrica subisce un forte sbilanciamento di classe. [5] Difatti, modelli poco precisi nella localizzazione del difetto possono comunque ottenere punteggi complessivi artificialmente elevati per il solo fatto di classificare correttamente le vaste, e numericamente preponderanti, aree di sfondo sano, fallendo però nell'identificazione della vera e propria anomalia. [5]

- **PRO (Per-Region Overlap) e AU-PRO**

  Per superare i limiti statistici dell'AUROC a livello di pixel, è stata introdotta la metrica PRO, particolarmente efficace quando il dataset è dominato da anomalie di piccole dimensioni. [29]

  Il PRO valuta le prestazioni di localizzazione misurando l'esatta percentuale di sovrapposizione tra le previsioni binarie dell'algoritmo e le singole regioni del *ground truth* (la maschera reale del difetto). [29] A differenza del raggruppamento indiscriminato dei pixel, il PRO calcola questa sovrapposizione in modo indipendente per ciascuna componente connessa dell'anomalia; ciò garantisce che difetti di dimensioni molto diverse (come un micro-graffio o una vasta ammaccatura) abbiano lo stesso peso matematico, impedendo alle anomalie più estese di dominare la valutazione finale. [29] La misura definitiva, denominata AU-PRO, si ottiene calcolando l'area sotto la curva dei valori PRO in funzione dei tassi di falsi positivi tollerabili (FPR). [29]

  L'adozione di questa metrica ha rivelato che, a fronte di scenari industriali reali e altamente complessi (come quelli introdotti nel dataset MVTec AD 2), le prestazioni medie dei modelli all'avanguardia risultano ancora fortemente deficitarie, crollando al di sotto del 60% in termini di AU-PRO [14].

1.3 Obiettivi e Struttura della Tesi

Il presente lavoro di tesi si propone l'obiettivo di analizzare in modo critico e comparativo le prestazioni delle principali architetture di Deep Learning nello scenario del rilevamento non supervisionato delle anomalie industriali (Visual Anomaly Detection). In particolare, l'indagine mira a valutare il comportamento di modelli basati su paradigmi teorici differenti — quali il modellamento geo-

metrico degli embedding, i Normalizing Flows e la distillazione della conoscenza — evidenziandone i punti di forza e le limitazioni intrinseche quando applicati alle due macro-categorie del dataset MVTec AD: le texture e gli oggetti strutturati. Un ulteriore obiettivo cardine consiste nel verificare l'impatto di strategie mirate di fine-tuning e nell'investigare la sensibilità delle reti a variazioni delle caratteristiche dell'immagine, come il colore e l'illuminazione.

Al fine di rispondere a tali obiettivi, l'elaborato è strutturato secondo il percorso qui delineato:

- Il **Capitolo 2** offre una rassegna approfondita dello stato dell'arte e della tassonomia dei metodi, tracciando l'evoluzione storica dai modelli generativi classici fino alle più moderne architetture basate su embedding (PaDiM), Normalizing Flows (FastFlow) e Teacher-Student (RD4AD).
- Il **Capitolo 3** descrive la metodologia e la configurazione sperimentale adottata, illustrando i criteri di selezione dei modelli oggetto dello studio, i framework software impiegati e le strategie di riaddestramento parziale.
- Il **Capitolo 4** è dedicato alla presentazione e alla discussione dei risultati quantitativi, analizzando i dati prestazionali sia a livello globale sia attraverso una scomposizione verticale tra i subset "Oggetti" e "Texture".
- Il **Capitolo 5** rappresenta il nucleo critico e qualitativo del lavoro; in esso vengono esaminate le mappe di calore (anomaly maps), l'impatto della conversione in scala di grigi (Grayscale) e viene condotta un'accurata analisi dei casi di fallimento (*failure analysis*).
- Il **Capitolo 6**, infine, trae le conclusioni del lavoro svolto, proponendo linee guida operative per il contesto industriale, evidenziando i limiti della ricerca e delineando le prospettive e gli sviluppi futuri.

Capitolo 2

Stato dell'Arte

La visual anomaly detection rappresenta uno dei pilastri fondamentali e maggiormente sfidanti dell'apprendimento automatico e della computer vision.

A differenza dei sistemi di apprendimento tradizionali, che operano in contesti statici e chiusi, i modelli di AD nascono per gestire l'incertezza intrinseca degli ambienti dinamici e aperti, con l'obiettivo di riuscire ad estrarre, caratterizzare e modelare i pattern unicamente dai dati normali disponibili, sfruttando questa conoscenza pregressa per identificare gli elementi sconosciuti, ovvero le anomalie.[26][7]

Questo paradigma trova ampie applicazioni nel mondo reale, suddivise principalmente in tre grandi macro-aree[26]:

1. **Intelligent Manufacturing:** ispezione delle superfici e controllo qualità automatizzato per identificare i difetti di produzione.
2. **Medical Image Analysis:** supporto alle diagnosi mediante l'individuazione automatica di lesioni, masse tumorali o anomalie dei tessuti.
3. **Intelligent Security e Video Surveillance:** rilevamento di eventi rari, incidenti o comportamenti sospetti nei flussi stradali o nella sorveglianza pubblica.

2.0.1 Classificazione per Granularità

Come citato nel capitolo 1, la letteratura scientifica suddivide i metodi visivi in due categorie principali, in base alla risoluzione spaziale e alla granularità richiesta dall'output [26]:

- **Image-level Detection:** il modello esprime un giudizio binario o un punteggio (*anomaly score*) riferito all'intera immagine, indicando se contenga o meno un'anomalia.
- **Pixel-level Detection:** il modello esegue una segmentazione dell'immagine assegnando a ciascun pixel un punteggio di anomalia così da generare una mappa di calore (*anomaly map*).

Tabella 2.1: Tassonomia dei metodi di Visual Anomaly Detection (AD) per dominio e paradigma di apprendimento.

Dominio	Paradigma di Apprendimento	Architetture e Approcci Principali
Image Domain	Unsupervised Learning	CAEs, GANs, Student-Teacher, Normalizing Flows
	Self / Semi-Supervised Learning	SVDD, Approcci basati su feature geometriche
Video Domain	Unsupervised Learning	Spatio-Temporal CAEs, GANs, Modelli Ibridi (CNN-
	Weakly Supervised Learning	Multiple Instance Learning, CNN pre-addestrate

L'evoluzione tecnologica ha vissuto una netta divisione con l'avvento del Deep Learning. I metodi si sono evoluti attraverso tre principali approcci all'addestramento [7]:

- Supervised Learning: richiede un dataset bilanciato ed etichettato sia con campioni normali che con tutte le possibili classi di difetti.
- Unsupervised Learning: rappresenta lo standard *de facto* della disciplina, addestrando il modello esponendolo solo a campioni privi di difetti.
- Weakly Supervised Learning: utilizza etichette a livello di video o gruppo di immagini, senza specificare in quale frame o pixel fosse l'anomalia.

2.1 L'era del Pre-Deep Learning

Prima della diffusione delle reti neurali, la computer vision si affidava ad una pipeline sequenziale a due stadi: l'estrazione di feature artigianali (*handcrafted features*) seguita da un classificatore o stimatore statistico superficiale.[26]

I vettori più utilizzati si basavano su variazioni geometriche, fotometriche e di texture locali:

- **Descrittori di apparenza e istogrammi**: lo *Scale-Invariant Feature Transform (SIFT)* per l'estrazione di punti di interessi invarianti alla scala, gli *Histograms of Oriented Gradients (HOG)* per catturare le informazioni strutturali e i contorni visivi e i *Local Binary Patterns (LBP* per la codifica locale delle trame di texture superficiali.[26][8]
- **Metodi Basati su Filtri e Trasformate:** l'applicazione di banchi di filtri energetici come gli operatori di Canny e Sobel, i filtri di Gabor e le trasformate sequenziali di Fourier e Waveket per l'analisi energetica delle risposte spaziali e isolare le discontinuità.[23]

Una volta estratti i descrittori locali, i meccanismi decisionali si dividevano in tre principali filoni:[26]

1. **Stima di densità parametrica e non parametrica**

   La modellazione della distribuzione dei dati avviene tramite modelli misti gaussiani (GMM) o stimatori di Kernel della densità (KDE). Se la probabilità logaritmica di un campione di test risulta inferiore ad una certa soglia, viene classificato come anomalo.

2. **One-Class Classification (OCSVM e SVDD)**

   Utilizza tecniche geometriche volte a mappare le feature in uno spazio a dimensionalità superiore per definire un confine decisionale ottimale attorno alla sola classe normale.

3. **Modello temporali e di contesto**

   Vengono utilizzati i Campi Aleatori di Markov (MRF) per combinare i descrittori visivi con le variazioni dinamiche calcolate tramite flussi ottici locali (HOF).

Questi approcci, però, soffrivano pesantemente della *"Curse of dimensionality"* quando applicati direttamente a immagini ad alta risoluzione. Inoltre, la loro natura non end-to-end impediva l'ottimizzazione congiunta delle feature e del criterio di rilevamento, limitando la robustezza algoritmica difronte a rumore di fondo, variazioni di illuminazione e ombre complesse.[26]

2.2 L'Evoluzione dei metodi basati sul Deep Learning

L'integrazione del Deep Learning ha consentito di superae i limiti strutturali delle feature manuali, consentendo l'estrazione automatica di rappresentazioni semantiche multilivello. Inoltre, con il successo delle CNN, l'attenzione si concentrata su come sfruttare la loro capacità di astrazione per sviluppare approcci end-to-end. I metodi moderni di AD non supervisionata si articolano in cinque principali famiglie.[7]

2.2.1 Metodi basati sulla Ricostruzione (Reconstruction-based)

Il concetto principale si fonda sul concetto di compressione ridondante della conoscenza. Il modello viene addestrato a mappare un'immagine normale in uno spazio a bassa dimensionalità per poi tentare di ricostruire l'input originale tramite un percorso inverso.[26]

L'assunto alla base del modello è che questo non essendo mai stato esposto alle anomalie durante il training, non sarà in possesso di coefficienti necessari per descriverle, generando un errore di ricostruzione elevato quando sono presenti dei difetti.

- **Formule Chiave** Nella pipeline basate su autoencoder e misure strutturali come lo *Structural Similarity Index (SSIM)*, l'anomaly score spaziale, viene misurato combinando la distanza euclidea dei pixel e la consistenza strutturale locale:[8][26]

$$\mathcal{L}_{\text{rec}}(x, \hat{x}) = (1 - \alpha) \cdot \|x - \hat{x}\|_2 + \alpha \cdot (1 - \text{SSIM}(x, \hat{x}))$$

Nei modelli generativi avanzati come ad esempio **AnoGAN**, la ricerca dell'immagine normale più vicina richiede un'ottimizzazione iterativa nello spazio latente z. La funzione di perdita per aggiornare il vettore latente unisce la perdita di embedding residua e la discriminazione delle feature estratte da un livello intermedio del discriminatore (D_λ):[26]

$$\mathcal{L}_{\text{AnoGAN}}(z_\gamma) = (1-\lambda) \cdot \|x - G(z_\gamma)\|_1 + \lambda \cdot \|D_\lambda(x) - D_\lambda(G(z_\gamma))\|_1$$

- **Evoluzioni e varianti** Nel tempo i metodi sono stati soggetti a studi che hanno portato alla loro evoluzione e alla definizione di varianti degli stessi. In particolare:
  - **CAVGA (Constrained Adversarial Variational General Architecture)**
    Introduce meccanismi di attenzione visiva integrati tramite mappe Grad-CAM per costringere la rete a coprire l'intera area normale dell'immagine, bloccando contemporaneamente le risposte sulle aree esterne.
  - **DFR (Deep Feature Reconstruction)**
    Sposta il processo di ricostruzione dallo spazio dei pixel a quello delle feature multilivello estratte da CNN pre-addestrate, riducendo i falsi positivi su bordi complessi.

  Bisogna sottolineare che sebbene i modelli puramente ricostruttivi siano intuitivi e precisi nella localizzazione spaziale, possono generalizzare in modo eccessivo, riuscendo a ricostruire parzialmente anche le anomalie visive, invalidando l'ipotesi di partenza.[7]

2.2.2 Metodi basati sui flussi di normalizzazione (Normalizing Flow-Based

I Normalizing Flow sono architetture potenti capaci di apprendere trasformazioni matematiche biettive e invertibili tra la complessa distribuzione visiva delle immagini e una funzione di densità di probabilità semplice e nota.

Durante la fase di training, il modello punta a massimizzare la verosomiglianza logaritmica dei campioni normali. Nella fase di test, invece, l'immagine viene elaborata dalla rete e la densità di probabilità risultante funge direttamente da punteggio di anomalia (più bassa è la probabilità calcolata, più è alta la probabilità che si tratti di un difetto).[7]

- **Fomule Chiave** Alla base del metodo c'è il teorema del cambiamento di variabili. Se $Z = f(x)$ è la mappatura verso lo spazio latente Gaussiano, la densità di probabilità di un campione x si calcola considerando il determinante della matrice Jacobiana (J_f) della trasformazione:

$$p(x) = p(f(x)) \cdot |\det J_f(x)|$$

In fase di training, la rete massimizza la log-verosomiglianza sui dati normali:

$$\text{Log}(p(x)) = \text{Log}(p(f(x))) + \text{Log}(|\det J_f(x)|)$$

- **Evoluzioni e varianti** Nel tempo, lo studio del metodo ha portato evoluzioni dello stesso e lo sviluppo di varianti, come:
  - **DifferNet** Considerato uno dei primi modelli ad applicare i NF all'ispezione visiva, estraendo delle feature multi-scala per la classificazione a livello di immagini.
  - **CFlow-AD (Conditional Flow)** Il modello introduce blocchi di flussi condizionali per elaborare le piramidi di feature, abilitando la localizzazione del difetto a livello di singolo pixel.
  - **FastFlow** Questo modello risolve un limite enorme rispetto i precedenti che, per poter processare i dati, dovevano appiattire la matrice dell'immagine in un vettore 1D, distruggendo le relazioni spaziali. FastFlow utilizza reti convoluzionali 2D per i flussi, preservando le vicinanze strutturali dei pixel e migliorando la precisione.[7]

2.2.3 Metodi basati sulla Rappresentazione (Rapresentation-based

In questa categoria metodologica viene esclusa la complessa fase di addestramento deep del modello. Vengono impiegate reti neurali pre-addestrate esclusivamente come estrattori potenti di descrittori visivi *(feature extractor)*. L'anomaly score si ricava calcolando le distanze geometriche statistiche tra il vettore di test e l'insieme di vettori normali presenti in memoria.[7]

- **Formule Chiave** Gli algoritmi appartenenti a questa categoria superano la semplice distanza euclidea, utilizzando delle metriche statistiche che considerando la varianza. Per un patch (una specifica regione dell'immagine), l'anomalia viene calcolata utilizzando la distanza di Mahalanobis:

$$D_M(x) = \sqrt{(x-\mu)^T \Sigma^{-1} (x-\mu)}$$

  Dove x è la feature in esame, μ è il vettore medio calcolato sulle immagini normali in quella specifica posizione nello spazio, e Σ^{-1} è la matrice di covarianza inversa.

- **Evoluzioni e Varianti** Gli studi, dopo la definizione di questo metodo, hanno portato a diversi sviluppi, che hanno definito più varianti, tra le principali troviamo:
  - **SPADE** Estrae piramidi di feature e utilizza un classificatore KNN per cercare i vettori normali più simili per ogni singolo pixel. Risulta molto preciso ma esecutivamente lento data la ricerca dettagliata.[26]

- **PaDiM (Patch Distribution Modeling)** Modella la distribuzione delle patch tramite Gaussiane Multivariate per calcolare la distanza in modo efficiente senza necessariamente richidere una ricerca KNN continua.[7]
- **PatchCore** Attualmente, viene considerato lo stato dell'arte in ambito industriale. Raccoglie le feature in una *Memory Bank*, ma comprimendo l'archivio così da poter mantenere i FPS elevati senza saturare la RAM. Per far ciò utilizza un algoritmo che salva solo le feature essenziali, ovvero il *greedy coreset subsampling*.
- **CFA (Coupled-hypersphere-based Feature Adaptation** Supera il problema del "bias" delle reti pre-addestrate usando il transfer learning per adattare le feature estratte al dominio specifico, proiettandole su ipersfere matematiche.

2.2.4 Metodi basati sulla Data Augmentation

I metodi non supervisionati sono caratterizzati da un training con assenza totale di immagini anomali, per questo, questi algoritmi puntano a "fabbricare" difetti sintesici manipolando le immagini normali. Questo fa si che l'Anomaly Detection si trasformi in un compito *self-supervised* di segmentazione: il modello viene quindi allenato a trovare le false anomalie inserite dal programmatore.[7]

- **Formule Chiave** I modelli appena definiti utilizzando le funzioni di perdita classiche della segmentazione supervisionata per separare i pixel veri da quelli alterati.

$$\text{Loss}_{\text{Segmentazione}} = -\left[y \cdot \log(p) + (1-y) \cdot \log(1-p)\right]$$

  Dove

$$y$$

  è la maschera binaria del difetto finto (1 se è presente l'anomalia, 0 se l'immagine è sana) e

$$p$$

  è la previsione della rete.

- **Evoluzione e Varianti** Anche questo metodo presenta più evoluzioni dello stesso.
  - **CutPaste** La logica ritaglia in modo casuale piccole zone dell'immagine sana *(cropping)*, applica variazioni di colore o rotazioni, e le incolla in un altro punto dell'immagine. Un classificatore viene poi addestrato a riconscere se l'immagine è autentica o "incollata".[7]
  - **DREAM** Genera maschere di rumore da sovrapporre come texture. Vengono addestrate due reti simultaneamente: una per ricostruire l'immagine pulita e un discriminatore per tracciare i bordi del difetto simulato.

– **NSA (Natural Synthetic Anomalies** Questo metodo taglia patch da immagini differenti e le fonde in campioni sani utilizzando algoritmi di *Poisson image editing*, simulando irregolarità strutturali con sfumature decisamente realistiche.

Di seguito viene presentata un'analisi comparativa dei macro-approcci descritti, evidenziandone vantaggi e svantaggi sulla base di tre criteri principali: tempo di inferenza, consumo di memoria e accuratezza della localizzazione.

Tabella 2.2: Confronto riepilogativo delle principali famiglie di metodi per la Visual Anomaly Detection.

Categoria	**Modelli Esempio**	**Concetto Base**	**Vantaggi**	**Svantaggi**
Pre-Deep Learning	SIFT, HOG, LBP, GMM, OCSVM	Estrazione feature manuali + modelli statistici/geometrici.	Leggeri e interpretabili.	*Curse of dimensionality*; non end-to-end.
Ricostruzione	AE, VAE, AnoGAN, CAVGA, DFR	Compressione e ricostruzione. L'errore segna l'anomalia.	Intuitivi; buona localizzazione spaziale.	Generalizzazione eccessiva sui difetti.
Normalizing Flow	DifferNet, CFlow-AD, FastFlow	Mappatura biettiva su curva Gaussiana; stima di probabilità.	Base matematica stabile; inferenza veloce.	Addestramento esoso in termini di VRAM.
Rappresentazione	SPADE, PaDiM, PatchCore, CFA	Estrazione feature da reti preaddestrate e confronto distanze.	Altissime prestazioni; nessun training profondo.	Dipendenza dal dominio originario (ImageNet); consumo memoria.
Data Augmentation	CutPaste, DRAEM, NSA	Sintesi di difetti artificiali e task *self-supervised*.	Facile implementazione con loss classiche.	Difficoltà a replicare la fisica dei difetti reali.

2.3 Analisi critica e sfide aperte nell'Anomaly Detection

Nonostante l'introduzione delle architetture del Deep Learning abbiamo contribuito a rivoluzionare le prestazioni dei sistemi della Visual Anomaly Detection, il passaggio dagli ambienti di laboratorio ai contesti applicativi reali presenta ancora degli ostacoli significativi. La letteratura più recente, dopo un'analisi critica ha evidenziato come l'AD in ambito industriale sia frenata da problematiche che vanno oltre la pura precisione algoritmica, coinvolgendo l'acquisizione dei dati, la robustezza ambientale e l'integrazione hardware.[1][16]

Di seguito vengono analizzate le principali sfide ancora aperte che guidano la scena attuale della ricerca scientifica.

2.3.1 Il "Bias" di Dominio e l'Adattamento delle Feature

Attualmente, i metodi considerati allo stato dell'arte per l'applicazione industriale, come ad esempio quelli basati sulla Rappresentazione, si affidano principalmente a reti neutrali pre-addestrate su dataset generici di grandi dimensioni, come ImageNet.[22] Nonostante questa strategia risolva il problema del **cold-start**, ovvero riesca ad addestrare una rete profonda solo con campioni normali, introduce un forte "bias di dominio".[16] Le *feature* estratte dalle immagini naturali, spesso non possiedono la granularità necessaria per riuscire a descrivere in modo ottimale le micro-strutture di una texture industriale o le imperfezioni di un macchinario ad altra precisione; questa dipendenza rende necessario sviluppare nuove tecniche di *transfer learning* e di adattamento al dominio non supervisionato, capaci di sintonizzare i descrittori sulle specifiche peculiarità del task senza invalidare le prestazioni del modello.[16]

2.3.2 Scalabilità Computazionale ed Edge Computing

L'integrazione dei sistemi di rilevamento delle anomalie nelle linee di produzione reali impone spesso l'adozione di paradigmi di *Edge Computing*. In questi casi, gli algoritmi devono essere eseguiti direttamente su dispositivi periferici, quali telecamere smart o nodi IoT, strutturalmente penalizzati da stringenti vincoli in termini di memoria e capacità di calcolo. [17] Il contrasto tra la necessità operativa e i requisiti hardware delle architetture visive, anche le più performanti, genera colli di bottiglia che non si adattano alla produzione in tempo reale. Ad esempio, i modelli basati sulla memorizzazione delle caratteristiche, come PatchCore, sebbene utilizzano strategie di compressione, richiedono comunque l'archiviazione e la consultazione di enormi *Memory Bank* di campioni nominali per riuscire a calcolare i punteggi dell'anomalia in fase di test.[22] Anche l'implementazione del Deep Learning in contesti IoT contribuisce ad introdurre severe criticità legate principalmente all'efficienza energetica e alla latenza decisionale; di conseguenza, l'ottimizzazione strutturale dei modelli e lo sviluppo di nuove soluzioni *Lightweight Deep Learning* rimangono cruciali per colmare il divario tra efficacia teorica e applicabilità industriale.[17]

2.3.3 Ambienti Dinamici e Continual Anomaly Detection

Generalmente, il paradigma della VAD presuppone un ambiente statico, ovvero, il modello apprende una singola definizione di "normalità" che rimane invariata per tutta la durata dell'inferenza. Tuttavia, nel mondo reale i dati sono soggetti a *Concept Drift*: cambiano le condizioni di illuminazione, l'usura dell'hardware, o anche variazioni concettuali del desing del prodotto. Di fronte a questa realtà, i modelli statici perdono calibrazione, generando un numero terribilmente elevato di falsi positivi.[11] La letteratura, per far fronte a queste criticità sta convergendo verso la *Continual Anomaly Detection*, con l'obiettivo di sviluppare dei sistemi in grado di aggiornare in modo incrementale la propria conoscenza della normalità in flussi dati continui, mitigando così la perdita drastica delle

informazioni acquisite in precedenza *(catastrophic forgetting)* durante le fasi di ri-addestramento.[11]

2.3.4 Prospettiva Zero-Shot e i Foundation Models

L'acquisizione di ampi set di dati normali risulta impraticabile in scenari di produzione altamente personalizzati o per piccoli lotti, per questo la ricerca si sta muovendo verso un approccio tendente alla *Zero-Shot Anomaly Detection*. Gli sviluppi più recenti, in particolare, esplorano l'utilizzo di modelli multi-modali molto potenti definiti *Foundation Models*, per rilevare le anomalie senza alcun addestramento specifico sul dominio.[25] Architetture emergenti, come il framework DCS, dimostrano la possibilità di integrare modelli visivo-linguistici per identificare e segmentare difetti complessi guidando l'attenzione della rete attraverso prompt testuali, riducendo così in modo drastico, i costi di setup e introducendo ispezioni industriali generalizzabili.[25]

Capitolo 3

Analisi comparativa dei modelli selezionati

3.1 Criteri di Selezione dei Modelli

La selezione dei quattro modelli analizzati in questo capitolo — **CCW-SSIM**, **PaDiM**, **RD4AD** e **FastFlow** — risponde all'esigenza di coprire in modo organico e completo i principali paradigmi e la loro evoluzione nell'ambito dell'Anomaly Detection (AD) non supervisionata applicata alle immagini industriali. Ciascuno di essi incarna una specifica filosofia metodologica descritta nel Capitolo 2, mostrando come la ricerca sia passata dall'elaborazione classica dei pixel e da metriche di somiglianza strutturale a complesse stime probabilistiche o di allineamento delle feature in spazi latenti.

I modelli rappresentano i seguenti paradigmi:

- **CCW-SSIM** [3] rappresenta l'evoluzione dei *metodi basati sulla ricostruzione* (*Reconstruction-based*). Mentre i modelli classici basati su autoencoder (AE) misurano l'anomalia tramite la semplice distanza euclidea o l'indice SSIM standard limitato alla scala di grigi, CCW-SSIM integra concetti di elaborazione del segnale classica (la scomposizione in subbande orientate e multiscala tramite piramide steerable complessa) e dello spazio di colore percettivo S-CIELAB. Rappresenta quindi un punto d'incontro ideale tra la modellizzazione ispirata al sistema visivo umano e le capacità ricostruttive delle reti convoluzionali.

- **PaDiM** [9] si colloca nel paradigma dei *metodi basati sulla rappresentazione* (*Representation-based*). Esso supera la necessità di addestrare complesse reti neurali ad-hoc, sfruttando estrattori di caratteristiche preaddestrati su ImageNet. A differenza dei precedenti approcci basati su vicinato (come SPADE [26]), che soffrono di elevata complessità di tempo e memoria a causa di query k-NN continue, PaDiM modella localmente la di-

stribuzione normale tramite funzioni gaussiane multivariate, introducendo un compromesso ottimale fra efficienza e sensibilità spaziale.

- **RD4AD** [10] appartiene al paradigma di *ricostruzione delle feature* tramite *Knowledge Distillation* (distillazione della conoscenza). Il modello affronta il problema fondamentale dei filtri identici o simili in configurazioni Teacher-Student tradizionali (dove lo Student rischia di ricostruire correttamente anche le anomalie, riducendo la discrepanza delle feature). RD4AD risolve questo problema strutturalmente introducendo una pipeline asimmetrica formata da un Teacher Encoder (congelato) e uno Student Decoder (addestrabile) connessi da un collo di bottiglia informativo (bottleneck) che blocca il passaggio delle perturbazioni anomale.

- **FastFlow** [28] incarna la famiglia dei *metodi basati sui flussi di normalizzazione* (*Normalizing Flow-based*). Esso modella in modo esplicito la densità di probabilità dei dati. Mentre i flussi unidimensionali convenzionali (come DifferNet) appiattiscono le caratteristiche distruggendo la coerenza spaziale e richiedendo una lenta inferenza a finestre scorrevoli, FastFlow utilizza flussi bidimensionali (2D Normalizing Flows) implementati interamente con reti convoluzionali, permettendo inferenza end-to-end sull'intera immagine e preservando le relazioni strutturali di vicinato spaziale.

3.2 Analisi Dettagliata del Modello 1: CCW-SSIM

3.2.1 Architettura del network e Feature Extraction

Il modello CCW-SSIM non impiega estrattori pre-addestrati su ImageNet ma utilizza un autoencoder convoluzionale profondo (Deep Autoencoder) con struttura simmetrica, addestrato da zero per apprendere la ricostruzione di immagini sane.

L'architettura del network è composta da:

1. **Encoder**: Una sequenza di blocchi convoluzionali con filtri 3×3, ciascuno seguito da Batch Normalization, funzioni di attivazione LeakyReLU ed operazioni di Max-Pooling per dimezzare la risoluzione spaziale aumentando il numero di canali di feature. Questa fase condensa l'immagine di input in uno spazio latente a bassa dimensionalità (collo di bottiglia).

2. **Decoder**: Strutturato in modo speculare all'encoder. Utilizza operazioni di upsampling bilineare seguite da convoluzioni standard (o strati di convoluzione trasposta) per ricostruire progressivamente le dimensioni spaziali dell'immagine originaria, ripristinando la risoluzione e riducendo il numero di canali.

La feature extraction e il pre-processamento per il calcolo della perdita (loss) non avvengono tuttavia nello spazio colore RGB originale, bensì attraverso un disaccoppiamento dei canali volto a mimare la percezione umana: la componente cromatica viene elaborata tramite lo spazio colore opponente **S-CIELAB**, mentre la componente strutturale della luminanza viene scomposta tramite una **Piramide Steerable Complessa**.

La trasformazione spaziale S-CIELAB

La conversione da RGB a S-CIELAB si articola in passaggi matematici rigorosi per separare la luminanza dai canali cromatici opponenti. Dapprima, l'immagine RGB viene convertita nello spazio standard CIE 1931 XYZ tramite la trasformazione lineare:

$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} 0.412453 & 0.357580 & 0.180423 \\ 0.212671 & 0.715160 & 0.072169 \\ 0.019334 & 0.119193 & 0.950227 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix} \tag{3.1}$$

Successivamente, le coordinate XYZ vengono trasformate nello spazio cromatico opponente del sistema visivo umano, che comprende un canale di luminanza (O_1), un canale rosso-verde (O_2) e un canale blu-giallo (O_3):

$$\begin{bmatrix} O_1 \\ O_2 \\ O_3 \end{bmatrix} = M_{\text{opp}} \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} \tag{3.2}$$

Per simulare la limitata acuità spaziale dell'occhio umano per i dettagli cromatici rispetto a quelli di luminanza, ciascun canale opponente O_i viene filtrato spazialmente con un banco di filtri passa-basso f_i modellati come combinazioni lineari di Gaussiane 2D (la cui deviazione standard rispecchia i limiti di sensibilità della retina alle frequenze spaziali):

$$O_i^*(x, y) = O_i(x, y) * f_i(x, y) \quad \text{per } i \in \{1, 2, 3\} \tag{3.3}$$

Infine, le mappe cromatiche filtrate O_i^* vengono convertite nuovamente nello spazio standard CIE $L^*a^*b^*$, ottenendo i canali finali L^*, a^*, b^*. Il canale L^* racchiude le informazioni di luminanza geometrica e strutturale, mentre a^* e b^* ospitano esclusivamente i segnali di crominanza purificati dal rumore ad alta frequenza.

Decomposizione in Piramide Steerable Complessa

Il canale di luminanza L^* viene analizzato tramite una decomposizione in piramide steerable complessa a $S = 6$ scale e $O = 6$ orientazioni. Questa scomposizione lineare proietta l'immagine su una base di filtri passa-banda analitici (coppie in quadratura di fase), producendo coefficienti complessi ad ogni livello spaziale (x, y):

$$c_{s,o}(x, y) = a_{s,o}(x, y) + j \cdot b_{s,o}(x, y) = A_{s,o}(x, y)e^{j\theta_{s,o}(x,y)} \tag{3.4}$$

dove:

- $A_{s,o}(x,y) = |c_{s,o}(x,y)| = \sqrt{a_{s,o}^2(x,y) + b_{s,o}^2(x,y)}$ rappresenta l'ampiezza locale del coefficiente, proporzionale al contrasto locale della trama alla scala s e orientazione o.

- $\theta_{s,o}(x,y) = \text{atan2}(b_{s,o}(x,y), a_{s,o}(x,y))$ rappresenta la fase locale, legata alla struttura geometrica (bordi, valli, picchi).

3.2.2 Processo di training e inferenza

Il training dell'autoencoder convoluzionale avviene esclusivamente su patch di immagini normali privi di difetti. La rete impara a mappare le patch in uno spazio latente compresso e a ricostruirle minimizzando una funzione di perdita basata sulla metrica CCW-SSIM definita globalmente su tutte le patch P dell'immagine:

$$\mathcal{L}_{\text{CCW-SSIM}}(X,Y) = 1 - \frac{1}{|P|} \sum_{p \in P} \text{CCW-SSIM}(X_p, Y_p) \tag{3.5}$$

In fase di inferenza (test), il modello opera in due modalità alternative:

- **Predizione Patchwise**: L'immagine di test viene campionata tramite una finestra scorrevole con dimensione 256×256 e stride fisso di 16 pixel. Ciascuna patch viene elaborata individualmente e le ricostruzioni vengono ricomposte mediando i pixel nelle regioni di sovrapposizione. Questa modalità è robusta e riduce i falsi positivi sui bordi, ma comporta un elevatissimo carico computazionale dovuto al numero di passaggi di inferenza.

- **Predizione Imagewise**: L'autoencoder, essendo interamente convoluzionale, viene alimentato direttamente con l'immagine a piena risoluzione in un unico passo in avanti (forward pass). Questo riduce drasticamente i tempi di esecuzione (di oltre 100 volte), a scapito di una perdita di precisione dovuta all'adattamento delle dimensioni del padding e alle distorsioni geometriche locali.

3.2.3 Meccanismo di calcolo del punteggio di anomalia (Anomaly Scoring)

Il calcolo dell'indice CCW-SSIM combina formalmente le informazioni cromatiche percettive ricavate da S-CIELAB e la somiglianza strutturale ricavata dalla piramide complessa:

$$\text{CCW-SSIM}(x,y) = \text{CW-SSIM}(x,y) \cdot C_r(x,y) \tag{3.6}$$

La componente strutturale CW-SSIM viene valutata su una finestra spaziale locale di dimensione N (tipicamente una griglia 7×7) applicata sui coefficienti

complessi c_x dell'immagine reale e c_y dell'immagine ricostruita:

$$\text{CW-SSIM}(c_x, c_y) = \frac{2\left|\sum_{i=1}^{N} c_{x,i} c_{y,i}^{*}\right| + K}{\sum_{i=1}^{N} |c_{x,i}|^2 + \sum_{i=1}^{N} |c_{y,i}|^2 + K} \tag{3.7}$$

dove $c_{y,i}^{*}$ è il complesso coniugato del coefficiente $c_{y,i}$, mentre K è una costante di stabilizzazione positiva. Analizzando il numeratore della formula:

$$\left|\sum_{i=1}^{N} c_{x,i} c_{y,i}^{*}\right| = \left|\sum_{i=1}^{N} A_{x,i} A_{y,i} e^{j(\theta_{x,i} - \theta_{y,i})}\right| \tag{3.8}$$

si evince come la metrica tolleri traslazioni microscopiche (fino a frazioni di pixel) purché lo sfasamento spaziale $\Delta\theta = \theta_{x,i} - \theta_{y,i}$ sia uniforme per tutti i coefficienti della finestra locale. Se la variazione di fase è casuale (dovuta a un'anomalia geometrica o strutturale), i termini si annullano per interferenza distruttiva, abbassando il punteggio.

La componente cromatica C_r misura la deviazione dei soli canali di colore a^* e b^* tramite la differenza euclidea spaziale ΔE:

$$\Delta E(x, y) = \sqrt{(a_x^*(x, y) - a_y^*(x, y))^2 + (b_x^*(x, y) - b_y^*(x, y))^2} \tag{3.9}$$

$$C_r(x, y) = 1 - \frac{1}{k}\Delta E(x, y) \tag{3.10}$$

dove $k = 100$ è una costante che normalizza la deviazione cromatica. La mappa di anomalia a livello di pixel è definita da $1 - \text{CCW-SSIM}(x, y)$, mentre il punteggio finale a livello di immagine è il massimo valore rilevato nella mappa complessiva.

—

3.3 Analisi Dettagliata del Modello 2: PaDiM

3.3.1 Architettura del network e Feature Extraction

Il modello PaDiM non richiede un processo di addestramento profondo. Esso si avvale di una rete convoluzionale pre-addestrata su ImageNet che funge da estrattore di caratteristiche spaziali multilivello (*feature extractor*), con tutti i parametri bloccati. Le architetture comunemente impiegate come spina dorsale (*backbone*) sono ResNet18, Wide-ResNet-50-2 o EfficientNet-B5.

Selezione dei blocchi intermedi del backbone

Per bilanciare la capacità discriminativa locale e il contesto semantico globale, PaDiM estrae le caratteristiche dai primi tre blocchi della rete (Layer 1, Layer 2 e Layer 3 in una ResNet):

- **Layer 1** produce una mappa $F^1 \in \mathbb{R}^{C_1 \times H_1 \times W_1}$ ad alta risoluzione spaziale, contenente informazioni legate a trame, bordi definiti e micro-dettagli cromatici.

- **Layer 2** fornisce una mappa $F^2 \in \mathbb{R}^{C_2 \times H_2 \times W_2}$ con risoluzione spaziale dimezzata e un maggior numero di canali, incorporando forme geometriche intermedie.

- **Layer 3** fornisce una mappa $F^3 \in \mathbb{R}^{C_3 \times H_3 \times W_3}$ con risoluzione spaziale ridotta a un quarto, che cattura relazioni spaziali macroscopiche e semantica di contesto.

Poiché le tre mappe di caratteristiche hanno risoluzioni geometriche diverse a causa degli stride convoluzionali, le mappe a risoluzione inferiore (F^2 e F^3) vengono allineate alla risoluzione massima $H_1 \times W_1$ (pari a un quarto dell'immagine originale, es. 56×56 per un input 224×224) tramite un'interpolazione bilineare:

$$\tilde{F}^k(i,j) = \text{interpolate}(F^k, (H_1, W_1))_{i,j} \quad \text{per } k \in \{2,3\} \tag{3.11}$$

Successivamente, per ogni posizione spaziale $(i,j) \in [1,H_1] \times [1,W_1]$, i vettori di attivazione dei tre livelli vengono concatenati lungo la dimensione dei canali, formando un unico vettore di embedding multiscala w_{ij}:

$$w_{ij} = [F^1_{ij} \parallel \tilde{F}^2_{ij} \parallel \tilde{F}^3_{ij}] \in \mathbb{R}^D \tag{3.12}$$

dove la dimensione complessiva è $D = C_1 + C_2 + C_3$ (ad esempio, $D = 64+128+256 = 448$ per ResNet18, e $D = 256+512+1024 = 1792$ per Wide-ResNet-50-2).

Riduzione Casuale della Dimensionalità (Random Dimensionality Reduction)

L'inversione di matrici di covarianza su vettori di embedding con dimensione D elevata (specialmente per Wide-ResNet) risulterebbe computazionalmente proibitiva e instabile per via della ridondanza informativa. PaDiM aggira questo problema proiettando o selezionando casualmente un sottoinsieme fisso di indici di canali $J \subset \{1,\ldots,D\}$ con cardinalità $d \ll D$ (tipicamente $d = 100$ o $d = 550$):

$$x_{ij} = P_{\text{rand}} w_{ij} \in \mathbb{R}^d \tag{3.13}$$

Questa riduzione dimensionale casuale trova giustificazione teorica nel lemma di Johnson-Lindenstrauss: in uno spazio a dimensionalità sufficientemente alta, le distanze reciproche tra i punti vengono preservate con una distorsione minima se proiettate su un sottospazio casuale di dimensione adeguata. Sperimentalmente, questa scelta surclassa approcci classici come la PCA in termini di velocità e stabilità di accuratezza.

3.3.2 Processo di training e inferenza

Fase di training (Modellazione della Normalità)

L'addestramento non prevede alcuna retropropagazione dell'errore. Data una collezione di N immagini normali di addestramento, per ciascuna coordinata spaziale (i, j) nella griglia $H_1 \times W_1$ si estraggono i relativi vettori di embedding ridotti $\{x_{ij}^k, k = 1, \ldots, N\}$. Questi punti vengono utilizzati per stimare i parametri di una distribuzione Gaussiana Multivariata $\mathcal{N}(\mu_{ij}, \Sigma_{ij})$ associata localmente a ciascuna coordinata:

$$\mu_{ij} = \frac{1}{N} \sum_{k=1}^{N} x_{ij}^k \tag{3.14}$$

$$\Sigma_{ij} = \frac{1}{N-1} \sum_{k=1}^{N} (x_{ij}^k - \mu_{ij})(x_{ij}^k - \mu_{ij})^T + \epsilon I \tag{3.15}$$

Il termine ϵI rappresenta una regolarizzazione di Tikhonov (con $\epsilon = 0.01$ e I matrice identità $d \times d$) introdotta per garantire che la matrice di covarianza campionaria Σ_{ij} sia sempre definita positiva e quindi invertibile, evitando singolarità numeriche nei punti a bassissima varianza. Alla fine dell'addestramento, il modello è interamente definito dalla griglia di parametri stimati (μ_{ij}, Σ_{ij}) per ogni cella (i, j).

Fase di inferenza

Per un'immagine di test, si estraggono e riducono i vettori x_{ij} per ogni cella (i, j). La distanza di Mahalanobis calcolata rispetto alla gaussiana locale funge da punteggio locale. La mappa delle distanze viene riportata alla dimensione originaria dell'immagine $H \times W$ tramite interpolazione bicubica e levigata con un filtro Gaussiano a livello spaziale con deviazione standard $\sigma = 4$ per addolcire i passaggi di scala.

3.3.3 Meccanismo di calcolo del punteggio di anomalia (Anomaly Scoring)

La distanza di Mahalanobis $d_M(x_{ij})$ misura in modo statisticamente rigoroso quanto il vettore di test x_{ij} devii dalla distribuzione normale locale alla coordinata (i, j), pesando ciascuna coordinata in base alla sua varianza e covarianza:

$$d_M(x_{ij}) = \sqrt{(x_{ij} - \mu_{ij})^T \Sigma_{ij}^{-1} (x_{ij} - \mu_{ij})} \tag{3.16}$$

La matrice bidimensionale dei valori $d_M(x_{ij})$ costituisce l'anomaly map a livello di pixel. Il punteggio di anomalia globale assegnato all'intera immagine è determinato dal massimo valore registrato all'interno della mappa delle distanze di Mahalanobis locale:

$$S_{\text{image}} = \max_{(i,j)} d_M(x_{ij}) \tag{3.17}$$

—

3.4 Analisi Dettagliata del Modello 3: RD4AD

3.4.1 Architettura del network e Feature Extraction

Il modello RD4AD si basa sul paradigma della distillazione della conoscenza inversa (Reverse Distillation) ed è strutturato come una pipeline asimmetrica a tre stadi: un Teacher Encoder E (congelato), un blocco intermedio One-Class Bottleneck Embedding (OCBE) e uno Student Decoder D (addestrabili).

Figura 3.1: Schema strutturale del modello RD4AD con flusso asimmetrico invertito.

Teacher Encoder

Come spina dorsale per la feature extraction viene impiegata una rete ResNet o Wide-ResNet pre-addestrata e congelata. Da essa vengono catturati i feature map di tre livelli a diverse scale spaziali:

- $f_E^1 \in \mathbb{R}^{C_1 \times H_1 \times W_1}$
- $f_E^2 \in \mathbb{R}^{C_2 \times H_2 \times W_2}$
- $f_E^3 \in \mathbb{R}^{C_3 \times H_3 \times W_3}$

One-Class Bottleneck Embedding (OCBE)

Il modulo OCBE funge da collo di bottiglia ed è deputato a compattare le feature del Teacher. Si articola in due sottounità:

1. **Multi-scale Feature Fusion (MFF)**: Per allineare le tre mappe a risoluzioni geometriche differenti, la mappa ad alta risoluzione f_E^1 viene sottocampionata applicando una convoluzione 3×3 con stride 2, seguita da Batch Normalization e attivazione ReLU, per farla corrispondere alla dimensione di f_E^2. Il risultato viene concatenato con f_E^2 e a sua volta ulteriormente ridotto per essere accoppiato con f_E^3. Una convoluzione finale con kernel 1×1 comprime la dimensione dei canali accumulati in una singola mappa fusa F_{fuse}.

2. **One-Class Embedding (OCE)**: La mappa fusa F_{fuse} attraversa un blocco residuale profondo addestrabile (analogo al quarto blocco di una ResNet), che proietta l'informazione in un codice latente compresso ϕ. Poiché questo blocco è addestrato solo su campioni regolari, esso agisce da filtro passa-basso informativo, in grado di rappresentare i pattern regolari ma incapace di codificare dettagli estranei o anomali.

Student Decoder

Lo Student Decoder D è configurato in maniera speculare rispetto all'Encoder ma con flusso inverso. Riceve in input il codice latente compresso ϕ e, attraverso una catena di blocchi di convoluzione trasposta (de-convoluzione) con stride 2 e connessioni di salto (skip connections), tenta di ricostruire le feature multi-scala del Teacher a ritroso, generando tre mappe student corrispondenti:

- $f_D^3 \in \mathbb{R}^{C_3 \times H_3 \times W_3}$ (ricostruita per prima dall'embedding profondo)
- $f_D^2 \in \mathbb{R}^{C_2 \times H_2 \times W_2}$
- $f_D^1 \in \mathbb{R}^{C_1 \times H_1 \times W_1}$

3.4.2 Processo di training e inferenza

Addestramento del Modello

Durante la fase di addestramento su sole immagini normali, i pesi del Teacher Encoder E rimangono immutati. I parametri di OCBE e dello Student Decoder D vengono invece ottimizzati congiuntamente per minimizzare la perdita basata sulla similarità coseno locale delle feature in ciascun punto spaziale (h, w) e per ogni livello k:

$$\mathcal{L}_{\text{sim}}^k(h,w) = 1 - \frac{\langle f_E^k(h,w), f_D^k(h,w) \rangle}{\|f_E^k(h,w)\|_2 \cdot \|f_D^k(h,w)\|_2} \tag{3.18}$$

La funzione di perdita di distillazione complessiva da minimizzare è definita come la somma pesata sui tre livelli convoluzionali:

$$\mathcal{L}_{\text{KD}} = \sum_{k=1}^{3} \frac{1}{H_k W_k} \sum_{h=1}^{H_k} \sum_{w=1}^{W_k} \mathcal{L}_{\text{sim}}^k(h,w) \tag{3.19}$$

Meccanismo di inferenza

In fase di test, se l'immagine presenta un'anomalia, il Teacher Encoder ne estrarrà i relativi pattern all'interno delle mappe f_E^k. Tuttavia, poiché il bottleneck OCBE e lo Student Decoder sono stati addestrati a decodificare unicamente rappresentazioni sane a partire dallo spazio compresso, essi falliranno nella ricostruzione di tali pattern anomali. Ciò determinerà un forte incremento della discrepanza locale $\mathcal{L}_{\text{sim}}^k(h,w)$ in corrispondenza del difetto.

3.4.3 Meccanismo di calcolo del punteggio di anomalia (Anomaly Scoring)

Le discrepanze locali calcolate per ogni livello costituiscono le mappe di errore del rispettivo blocco:

$$M^k(h,w) = \mathcal{L}_{\text{sim}}^k(h,w) \tag{3.20}$$

Ciascuna mappa di discrepanza M^k viene proiettata alla risoluzione originaria dell'immagine $H \times W$ tramite un operatore di interpolazione bilineare Ψ. Le mappe allineate vengono sommate spazialmente per generare la mappa di localizzazione finale S_{map}:

$$S_{\text{map}}(x, y) = \sum_{k=1}^{3} \Psi(M^k)(x, y) \tag{3.21}$$

La mappa S_{map} viene filtrata con un filtro Gaussiano per eliminare rumore ad alta frequenza. Il punteggio complessivo dell'immagine è calcolato prendendo il massimo valore presente nella mappa di localizzazione spaziale:

$$S_{\text{image}} = \max_{(x,y)} S_{\text{map}}(x, y) \tag{3.22}$$

—

3.5 Analisi Dettagliata del Modello 4: FastFlow

3.5.1 Architettura del network e Feature Extraction

Il modello FastFlow adotta una spina dorsale di estrazione di caratteristiche pre-addestrata e congelata accoppiata con un modello probabilistico basato su flussi di normalizzazione bidimensionali (2D Normalizing Flows).

Feature Extractor: CNN vs Vision Transformer

FastFlow supporta due categorie di estrattori di caratteristiche:

1. **CNN (es. ResNet18, Wide-ResNet-50-2)**: Vengono estratti i feature map dai primi tre blocchi per catturare diversi livelli di astrazione. Le caratteristiche multi-scala vengono elaborate da flussi di normalizzazione dedicati per ciascuna scala indipendente.

2. **Vision Transformer (es. DeiT-S, CaiT-S36)**: I Transformer elaborano le immagini proiettandole in patch e catturando relazioni globali e locali tramite strati di self-attention. Poiché ciascuna patch memorizza informazioni geometriche e semantiche integrate, FastFlow estrae le feature da un singolo livello intermedio o profondo del Transformer, eliminando la necessità di elaborare e fondere scale convoluzionali multiple.

Le feature così estratte vengono immesse in una cascata di N blocchi bidimensionali invertibili e biettivi (*flow steps*), che costituiscono il nucleo di FastFlow 2D.

3.5.2 Principio dei Flussi di Normalizzazione e Cambiamento di Variabili

L'obiettivo di un normalizing flow è mappare la complessa distribuzione delle feature normali di input $x \in \mathbb{R}^c$ verso una densità di probabilità nota e trattabile nello spazio latente $z \in \mathbb{R}^c$, definita da una distribuzione Gaussiana standard tridimensionale $\mathcal{N}(0, I)$. Se $z = f_\theta(x)$ è la funzione di trasformazione invertibile definita dalla rete con parametri θ, per il teorema del cambiamento di variabili la densità di probabilità di x è espressa come:

$$p_X(x) = p_Z(f_\theta(x)) \cdot \left| \det \frac{\partial f_\theta(x)}{\partial x} \right| \tag{3.23}$$

dove $\frac{\partial f_\theta(x)}{\partial x} = J_{f_\theta}(x)$ rappresenta la matrice Jacobiana della trasformazione. Applicando il logaritmo, si ottiene:

$$\log p_X(x) = \log p_Z(f_\theta(x)) + \log \left| \det J_{f_\theta}(x) \right| \tag{3.24}$$

Assumendo per il vettore latente la densità gaussiana isotropa:

$$p_Z(z) = (2\pi)^{-\frac{d}{2}} \exp\left(-\frac{1}{2} \|z\|^2 \right) \tag{3.25}$$

l'espressione diventa:

$$\log p_X(x) = -\frac{d}{2} \log(2\pi) - \frac{1}{2} \|f_\theta(x)\|_2^2 + \log \left| \det J_{f_\theta}(x) \right| \tag{3.26}$$

Struttura del Flow Step 2D

Per preservare la coerenza geometrica spaziale e rendere calcolabile in tempo reale il determinante dello Jacobiano, ciascuno degli N passaggi invertibili di FastFlow si compone di tre moduli operanti su tensori 2D:

1. Activation Normalization (ActNorm) Esegue una normalizzazione affine per canale tramite parametri scalari di dilatazione $s \in \mathbb{R}^C$ e traslazione $b \in \mathbb{R}^C$ appresi:

$$y_{c,h,w} = s_c \cdot x_{c,h,w} + b_c \tag{3.27}$$

I parametri sono inizializzati in modo che il primo batch di dati abbia media nulla e varianza unitaria. Il log-determinante dello Jacobiano per questo strato è pari a:

$$\log \left| \det J_{\text{ActNorm}} \right| = H \cdot W \cdot \sum_{c=1}^{C} \log |s_c| \tag{3.28}$$

2. Channel Permute Applica una permutazione deterministica 1D fissa lungo la dimensione dei canali. Questa operazione assicura che tutte le componenti del canale si mescolino prima del coupling layer successivo. Essendo equivalente a una matrice di permutazione ortogonale, il determinante dello Jacobiano è ± 1, e il suo log-determinante è pari a 0.

3. 2D Affine Coupling Layer Il tensore in ingresso $x \in \mathbb{R}^{C\times H\times W}$ viene diviso lungo l'asse dei canali in due metà: $x_a \in \mathbb{R}^{C_a\times H\times W}$ e $x_b \in \mathbb{R}^{C_b\times H\times W}$ (con $C_a = C_b = C/2$).

- La prima metà rimane inalterata:

$$y_a = x_a \tag{3.29}$$

- La seconda metà subisce una trasformazione affine controllata da due reti interamente convoluzionali $s(\cdot)$ e $b(\cdot)$ alimentate da y_a:

$$y_b = x_b \odot e^{s(y_a)} + b(y_a) \tag{3.30}$$

Le funzioni subnetwork convoluzionali $s(y_a)$ e $b(y_a)$ non necessitano di essere invertibili. La biettività globale è garantita dalla formulazione strutturale. La trasformazione inversa è infatti immediata:

$$x_a = y_a \tag{3.31}$$

$$x_b = (y_b - b(y_a)) \odot e^{-s(y_a)} \tag{3.32}$$

Poiché la matrice Jacobiana del coupling layer ha una struttura triangolare a blocchi:

$$J_{\text{coupling}} = \begin{bmatrix} I & 0 \\ \frac{\partial y_b}{\partial x_a} & \operatorname{diag}\left(e^{s(x_a)}\right) \end{bmatrix} \tag{3.33}$$

il suo determinante coincide con il prodotto degli elementi diagonali, riducendo il calcolo del log-determinante alla semplice somma spaziale e di canale dei coefficienti di scala:

$$\log|\det J_{\text{coupling}}| = \sum_{h=1}^{H}\sum_{w=1}^{W}\sum_{c=1}^{C_b} s(x_a)_{c,h,w} \tag{3.34}$$

3.5.3 Processo di training e inferenza

Addestramento (NLL Loss)

Il modello FastFlow viene addestrato massimizzando la verosimiglianza dei campioni normali. L'ottimizzazione minimizza la perdita di log-verosimiglianza negativa (NLL) rispetto a tutti i parametri θ dei coupling layer:

$$\mathcal{L}_{\text{NLL}}(\theta) = \sum_k \left[\frac{1}{2}\|f_{\theta_k}(x^k)\|_2^2 - \sum_{i=1}^{N}\log\left|\det J_i^k\right|\right] \tag{3.35}$$

dove l'indice k scorre sulle scale delle feature e i indica i vari flow steps.

Fase di inferenza

In fase di test, l'immagine viene processata e proiettata nello spazio latente tramite il cammino diretto del flow. Le caratteristiche sane ricadranno in zone ad alta densità (vicino all'origine dello spazio latente Gaussiano), mentre le caratteristiche anomale verranno proiettate in regioni a bassissima verosimiglianza.

3.5.4 Meccanismo di calcolo del punteggio di anomalia (Anomaly Scoring)

Il punteggio di anomalia spaziale per ciascuna coordinata (h, w) alla scala k viene definito direttamente dall'intensità quadratica locale del vettore latente $z^k = f_{\theta_k}(x^k)$ (che domina il calcolo probabilistico):

$$A^k(h, w) = \frac{1}{2}\|z^k(h, w)\|_2^2 \tag{3.36}$$

Le mappe probabilistiche A^k di ciascuna scala vengono interpolate bilinearmente alla risoluzione originaria dell'immagine $H \times W$ e sommate spazialmente per strutturare l'anomaly map finale S_{map}:

$$S_{\text{map}}(x, y) = \sum_k \Psi(A^k)(x, y) \tag{3.37}$$

Il punteggio a livello di immagine è infine estratto come il valore massimo all'interno dell'anomaly map:

$$S_{\text{image}} = \max_{(x,y)} S_{\text{map}}(x, y) \tag{3.38}$$

Grazie all'architettura interamente convoluzionale dei blocchi di accoppiamento 2D, l'intero calcolo avviene end-to-end senza ricorrere a finestre scorrevoli tridimensionali, garantendo un'altissima velocità d'inferenza.

Bibliografia

[1] Abdelrahman Alzarooni, Ehtesham Iqbal, Samee Ullah Khan, Sajid Javed, Brain Moyo, and Yusra Abdulrahman. Anomaly detection for industrial applications, its challenges, solutions, and future directions: A review. *arXiv preprint arXiv:2501.11310*, 2024.

[2] Aimira Baitieva, David Hurych, Victor Besnier, and Olivier Bernard. Supervised anomaly detection for complex industrial images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 17754–17762, 2024.

[3] Simone Berasi. Ccw-ssim: a novel color-enhanced structural similarity metric applied to autoencoders for anomaly detection. Master's thesis, Politecnico di Milano, 2023.

[4] Paul Bergmann, Kilian Batzner, Michael Fauser, David Sattlegger, and Carsten Steger. The mvtec anomaly detection dataset: A comprehensive real-world dataset for unsupervised anomaly detection. *International Journal of Computer Vision*, 129(4):1038–1059, 2021.

[5] João P. C. Bertoldo, Dick Ameln, Ashwin Vaidya, and Samet Akçay. Aupimo: Redefining anomaly localization benchmarks with high speed and low tolerance. In *Proceedings of the British Machine Vision Conference (BMVC)*, 2024.

[6] Yunkang Cao, Xiaohao Xu, Jiangning Zhang, Yuqi Cheng, Xiaonan Huang, Guansong Pang, and Weiming Shen. A survey on visual anomaly detection: Challenge, approach, and prospect. *arXiv preprint arXiv:2401.16402*, 2024.

[7] Yajie Cui, Zhaoxiang Liu, and Shiguo Lian. A survey on unsupervised anomaly detection algorithms for industrial images. *IEEE Access*, 11:55297–55315, 2023.

[8] Yajie Cui, Zhaoxiang Liu, and Shiguo Lian. A survey on unsupervised anomaly detection algorithms for industrial images. *IEEE Access*, 11:55297–55315, 2023.

[9] Thomas Defard, Aleksandr Setkov, Angelique Loesch, and Romaric Audigier. Padim: a patch distribution modeling framework for anomaly detection and localization. In *International Conference on Pattern Recognition (ICPR)*, pages 4790–4797, 2021.

[10] Hanqiu Deng and Xingyu Li. Anomaly detection via reverse distillation from one-class embedding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4477–4486, 2022.

[11] Kamil Faber, Christopher Kanan, Vincenzo Lomonaco, and Roberto Corizzo. Continual anomaly detection: A comprehensive survey and research roadmap. *Preprints.org*, 2026.

[12] David Guthrie, Louise Guthrie, Ben Allison, and Yorick Wilks. Unsupervised anomaly detection. In *Proceedings of the 20th International Joint Conference on Artificial Intelligence (IJCAI)*, pages 1624–1628, 2007.

[13] Lars Heckler-Kram, Jan-Hendrik Neudeck, Ulla Scheler, Rebecca Konig, and Carsten Steger. The mvtec ad 2 dataset: Advanced scenarios for unsupervised anomaly detection. *arXiv preprint arXiv:2503.21622*, 2025.

[14] Lars Heckler-Kram, Jan-Hendrik Neudeck, Ulla Scheler, Rebecca König, and Carsten Steger. The mvtec ad 2 dataset: Advanced scenarios for unsupervised anomaly detection. *International Journal of Computer Vision*, 134(4):175–197, 2026.

[15] Tangqing Li, Zheng Wang, Siying Liu, and Wen-Yan Lin. Deep unsupervised anomaly detection. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 3636–3645, 2021.

[16] Zhuo Li, Yuhao Yan, Xiangheng Wang, Yifei Ge, and Lin Meng. A survey of deep learning for industrial visual anomaly detection. *Artificial Intelligence Review*, 58(9):279, 2025.

[17] Roya Morshedi and S. Mojtaba Matinkhah. A comprehensive review of deep learning techniques for anomaly detection in iot networks: Methods, challenges and datasets. *Engineering Reports*, 7(9):e70415, 2025.

[18] MVTec. The mvtec logical constraints anomaly detection dataset.

[19] G. Pang, C. Shen, L. Cao, and A. Van Den Hengel. Deep learning for anomaly detection: A review. *ACM Computing Surveys (CSUR)*, 54(2):1–38, 2021.

[20] Guansong Pang, Longbing Cao, and Charu Aggarwal. Deep learning for anomaly detection: Challenges, methods, and opportunities. In *Proceedings of the 14th ACM International Conference on Web Search and Data Mining (WSDM)*, pages 1127–1130, 2021.

[21] Jing Ren, Feng Xia, Yemeng Liu, and Ivan Lee. Deep video anomaly detection: Opportunities and challenges. In *Proceedings of the International Conference on Data Mining Workshops (ICDMW)*, pages 959–966, 2021.

[22] Karsten Roth, Latha Pemula, Joaquin Zepeda, Bernhard Scholkopf, Thomas Brox, and Peter Gehler. Towards total recall in industrial anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14318–14328, 2022.

[23] Tung Minh Tran, Tu N. Vu, Nguyen D. Vo, Tam V. Nguyen, and Khang Nguyen. Anomaly analysis in images and videos: A comprehensive review. *ACM Computing Surveys*, 55(7):148:1–148:37, 2022.

[24] Miryam Elizabeth Villa-Pérez, Miguel Á. Álvarez-Carmona, Octavio Loyola-González, Miguel Angel Medina-Pérez, Juan Carlos Velazco-Rossell, and Kim-Kwang Raymond Choo. Semi-supervised anomaly detection algorithms: A comparative summary and future research directions. *Knowledge-Based Systems*, 218:106878, 2021.

[25] Y. Wan, Y. Lang, and L. Yao. Dcs: A zero-shot anomaly detection framework with dino-clip-sam integration. *Applied Sciences*, 16(4):1836, 2026.

[26] Jie Yang, Ruijie Xu, Zhiquan Qi, and Yong Shi. Visual anomaly detection for images: A survey. *arXiv preprint arXiv:2109.13157*, 2021.

[27] Min Yang and Jiajie Zhang. Data anomaly detection in the internet of things: A review of current trends and research challenges. *International Journal of Advanced Computer Science and Applications*, 14(9), 2023.

[28] Jiawei Yu, Ye Zheng, Xiang Wang, Wei Li, Yushuang Wu, Rui Zhao, and Liwei Wu. Fastflow: Unsupervised anomaly detection and localization via 2d normalizing flows. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.

[29] Ye Zheng, Xiang Wang, Yu Qi, Wei Li, and Liwei Wu. Benchmarking unsupervised anomaly detection and localization. *arXiv preprint arXiv:2205.14852*, 2022.